Ontología para la exploración musical

Segunda entrega | Grupo 2 | Octubre de 2026

1. Modelo y cambios justificados

El explorador conecta grabaciones, artistas, composiciones, ediciones, sellos y análisis acústicos. El esquema contiene 19 clases y 70 propiedades (21 de objeto y 49 de datos). Parte de 39 CSV y 100.000 referencias locales de grabación.

Cambio	Justificación semántica
Retirar RegistroDataset y RegistroCancion del núcleo musical.	Una fila es evidencia de datos. La procedencia se conserva con CapturaFuente y la huella de cada CSV.
Retirar AfirmacionExterna. Usar compuso, produjo e interpretaObra.	Las relaciones tipadas expresan directamente el papel musical y permiten consultarlo.
Distinguir obra de grabación y edición de grupo de lanzamientos.	Una composición admite varias grabaciones. Varias ediciones pueden pertenecer al mismo álbum, sencillo o EP.
Conservar CreditoArtistico y AnalisisAcustico como entidades.	El crédito tiene artista, posición y captura. El análisis reúne mediciones de una misma observación.
Conservar PublicacionDiscografica y AsignacionGenero.	El catálogo depende del par edición–sello. El género puede tener papel, votos y procedencia. Una relación simple perdería esos atributos.

Jerarquía, identidad y etiquetas

Persona y Agrupacion especializan Artista. Album, Sencillo y EP especializan GrupoLanzamientos. Compositor y productor se modelan como roles. El dominio de tieneCredito es una *unión* de Grabacion y GrupoLanzamientos. Declarar dos dominios separados impondría ambas clases.

Las URI locales usan track_id. Los recursos externos conservan sus identificadores. No se deduce igualdad por nombre ni desigualdad por tener URI diferentes. Los nodos anónimos servirían para asociaciones sin identidad pública, pero no reemplazan su significado ni sus atributos. Aquí se usan URI estables para trazabilidad.

Todas las clases, propiedades e instancias tienen etiquetas no vacías con idioma. Se utiliza `@es` para descripciones generadas, `@und` cuando el idioma del nombre no está verificado y el idioma de origen para Wikidata. Solo se exceptúan estructuras OWL y listas RDF.

Formalización RDF y RDFS

El código genera Turtle reproducible con RDFLib. RDF expresa tipos de instancias, RDFS expresa subclases, dominios y rangos, y OWL incorpora los axiomas de la página siguiente. Los dominios y rangos permiten inferir tipos, no actúan como validaciones de campos.

Propiedad	Dominio	Rango
interpretaObra	Grabacion	ObraMusical
tempoBPM	AnalisisAcustico	Decimal

2. Axiomas OWL y evidencia

ID	Construcción	Significado y justificación
A01	Clases disjuntas	Persona y Agrupacion son disjuntas porque un artista individual no es un colectivo.
A02	Clases disjuntas	Grabacion y ObraMusical son disjuntas porque la realización sonora se distingue de la composición.
A03	Clases disjuntas	Lanzamiento y GrupoLanzamientos son disjuntas porque una edición no es el grupo que reúne ediciones.
A04	Propiedades inversas	apareceEn y contieneGrabacion permiten recorrer en ambos sentidos la inclusión en una edición.
A05	Propiedades inversas	interpretaObra y tieneGrabacion permiten recorrer el vínculo entre composición y realización.
A06	Propiedades inversas	perteneceAGrupo y tieneLanzamiento permiten recorrer la pertenencia editorial en ambos sentidos.
A07	Propiedades inversas	tieneCredito y acreditaEntidad permiten recorrer el vínculo entre el crédito y su sujeto.
A08	Cardinalidad exacta	Un CreditoArtistico tiene exactamente un artistaAcreditado de clase Artista.
A09	Cardinalidad exacta	Un CreditoArtistico acredita exactamente una entidad de la unión Grabacion o GrupoLanzamientos.
A10	Cardinalidad exacta	Una AsignacionGenero tiene exactamente un generoAsignado de clase GeneroMusical.
A11	Cadena de propiedades	tienePublicacion seguida de selloPublicacion implica publicadoPor. El sello de la asociación editorial publica esa edición.

Mundo abierto. Un valor ausente es desconocido. Una cardinalidad no valida completitud. Para probar una contradicción por dos valores se requiere establecer que son diferentes. Los controles de archivos se ejecutan por separado.

Evidencia HermiT. El esquema es consistente y no tiene clases insatisfacibles. Se comprobaron seis inferencias (cuatro inversas, una cadena y una jerarquía) y se detectaron dos contradicciones deliberadas. El resultado se registra en `docs/etapa2/evidencia/razonamiento.json`. Se evaluó el esquema completo y casos controlados, no toda la población. Fuseki consulta los triples explícitos sin razonamiento OWL automático.

3. Preguntas 1–4 y evidencia de respuesta

Extractos reales de resultados completos, sin LIMIT. Nombres añadidos desde los CSV para lectura. URI completas en muestras_consultas.json. Los identificadores abreviados se marcan con puntos suspensivos.

PC 1. ¿Qué grabaciones tienen Rock como género mayoritario y un tempo medido superior a 120 BPM?

Grabación	Género / papel	BPM
Chasing shadows	Rock / mayoritario	126,966911316
Ionized	Rock / mayoritario	138,80859375

Rock corresponde al vocabulario tagtraum. Cada tempo pertenece a un análisis de la grabación.

PC 2. ¿Qué grabaciones acreditan al menos a dos artistas distintos y en qué orden aparecen esos artistas en los créditos de la grabación?

Grabación	Artista acreditado	Posición
Boo	Randy Brecker	1
Boo	Peter Erskine	2

Extracto de la misma captura de créditos masivos, SHA-256 229a3da2…. Orden original en base uno.

PC 3. ¿Qué obras musicales tienen al menos dos grabaciones distintas que, en conjunto, acreditan al menos a dos artistas distintos, y qué compositores están asociados a esas obras, si se dispone de esa información?

Obra / MBID grabación	Artista	Compositor
Lodi / 16803c92…	The Flying Burrito Brothers	John Fogerty
Lodi / 191a9b8f…	Tesla	John Fogerty

Dos MBID diferentes y dos artistas en conjunto. Se conservan grabaciones sin créditos cuando la obra satisface ambos umbrales.

PC 4. ¿Qué grabaciones aparecen en al menos dos lanzamientos distintos y a qué grupo de lanzamientos pertenece cada uno?

Grabación	Edición (MBID)	Grupo
Chasing shadows	ad7dbae7…	Law of Retaliation
Chasing shadows	e27bd6df…	Law of Retaliation

Son dos ediciones distintas del mismo grupo 3b626171…. Un título compartido no las convierte en una sola edición.

4. Preguntas 5–8 y evidencia de respuesta

PC 5. ¿Qué sellos discográficos publicaron al menos dos lanzamientos distintos y cuáles son los títulos y los números de catálogo de esos lanzamientos?

Sello	Título del lanzamiento	Catálogo
Atlantic	Yesterdays	AMCY-15
Atlantic	Running in Real Time	7 81251-4

El catálogo pertenece a la asociación de cada edición con Atlantic.

PC 6. ¿Qué grabaciones acreditan tanto a un artista individual como a una agrupación musical?

Grabación	Persona	Agrupación
Boo	Tim Hagans	Norrbotten Big Band

Ambos créditos pertenecen a la misma captura 229a3da2….

PC 7. ¿Qué análisis de AcousticBrainz reportan tanto una tonalidad de do mayor como un tempo superior a 120 BPM y qué grabaciones describen esos análisis?

Análisis / grabación	Tonalidad	BPM
0026bc86…/ Mona Lisa Eyes	C / major	146,966278076
00286722…/ Little Pig	C / major	165,433990479

Fuente acousticbrainz_dump. Tonalidad y tempo se comprobaron en la misma fila de análisis.

PC 8. Para cada género musical, ¿cuántas grabaciones, artistas y grupos de lanzamientos están clasificados en él, contando por separado cada una de estas tres categorías?

Género por vocabulario / ID	Grab.	Art.	Grupos
tagtraum / Rock	13.924	0	0
Wikidata / Q11366	0	1.129	0
MusicBrainz / 02b2f720…	0	0	544

Conteos independientes por URI de género. Cero significa que no hay miembros registrados en esa categoría. No afirma que no existan. No se fusionan vocabularios por etiqueta.

Cómo inspeccionar cada extracto

El número PC identifica el archivo `01_*.rq` hasta `08_*.rq`. `docs/etapa2/evidencia/muestras_consultas.json` conserva las filas originales y las etiquetas añadidas. Los resultados completos se adjuntan comprimidos en `docs/etapa2/resultados`. CSV y JSON sin comprimir están en el paquete de entrega.

5. Auditoría de las respuestas completas

Un cálculo independiente sobre los CSV, sin ejecutar SPARQL ni importar el generador RDF, reconstruyó las respuestas esperadas. Se compararon **todas las filas y columnas**, normalizando los decimales por valor. Las huellas de fuentes, consultas y resultados quedan en `auditoria_consultas.json`.

PC	Esperadas	Obtenidas	Sobran	Faltan
1	2.731	2.731	0	0
2	2.350	2.350	0	0
3	278	278	0	0
4	63.643	63.643	0	0
5	56.819	56.819	0	0
6	489	489	0	0
7	789	789	0	0
8	1.968	1.968	0	0

No se encontraron filas duplicadas. Las filas no equivalen siempre a entidades. PC1 cubre 2.709 grabaciones y PC2 cubre 1.042. PC3 comprende 96 obras y PC4 comprende 15.635 grabaciones. PC5 incluye 4.388 sellos y PC6 incluye 389 grabaciones. PC7 abarca 789 análisis y PC8 abarca 1.968 géneros.

Información que la fuente no permite completar

Campo no ligado	Filas	Tratamiento
PC3. Compositor	44	Se devuelve la obra sin inventar un compositor.
PC4. Grupo de lanzamientos	40	Se conserva la edición. Su grupo es desconocido.
PC5. Número de catálogo	9.932	Se conserva la publicación. Su catálogo es desconocido.

Estas respuestas son correctas respecto de los datos disponibles, pero esas filas no ofrecen toda la información solicitada. OPTIONAL hace explícita la incompletitud. La coincidencia del cálculo no garantiza la veracidad de la fuente ni completa el mundo abierto.

Regresiones sobre el significado

Las pruebas comprueban la separación de capturas y análisis, el conteo por MBID en PC3, la conservación de grabaciones sin créditos, la asociación correcta de catálogos con sellos y los conteos sin multiplicación por asignaciones repetidas.

6. Entrega, ejecución y controles

Evidencia	Resultado registrado
Esquema / instancias en Fuseki	466 / 7.606.648 triples distintos. Total 7.607.114.
Carga y consultas HTTP	Dos cargas con HTTP 201 y ocho consultas con HTTP 200.
Cobertura de identidad	100.000 referencias. 32.175 correspondencias aceptadas. 32.140 MBID distintos.
Etiquetas de instancias	742.915 recursos etiquetados. Controles sin faltantes ni idiomas inválidos.
Integridad de relaciones	Sin créditos o asignaciones que incumplan los controles de cardinalidad exportada. Sin conflictos explícitos de tipos disjuntos.

Reproducción desde la raíz del repositorio

```
python -m pip install -r requirements.txt
python src/generar_ontologia.py
python src/generar_instancias.py
python src/validar_instancias.py
docker compose up -d --build
python src/cargar_fuseki.py
python src/consultar_etapa2.py
python src/auditar_consultas.py
python src/generar_evidencias_consultas.py
python -m unittest discover -s tests
```

Fuseki 6.2.0 usa TDB2 persistente y dos grafos nombrados con unión predeterminada. La configuración está centralizada en `src/configuracion.py`. HermiT se reproduce con `requirements-owl.txt` y `python src/verificar_owl.py --docker-java`.

Archivos adjuntos y alcance

El ZIP incluye esquema, instancias, 39 CSV, código, consultas, resultados, evidencias, README, LaTeX y PDF. Un manifiesto SHA-256 identifica cada archivo. El catálogo completo, el mapeo y las decisiones detalladas están en `docs/etapa2`.

Problemas encontrados y soluciones

Las capturas piloto y masivas difieren en cobertura. Se conservaron por separado para no mezclar créditos ni mediciones. Varias referencias locales comparten MBID, por lo que PC3 cuenta identificadores externos. Los metadatos incompletos se mantienen como valores desconocidos mediante OPTIONAL. La escritura incremental resuelve el volumen de 1,69 GB del Turtle.

El bonus de extracción desde texto es opcional y no se implementó. La alineación con ontologías externas corresponde a una etapa posterior.

Referencias. W3C, OWL 2 Primer y RDF Schema 1.1. Apache Jena, configuración de Fuseki. MusicBrainz, Release Group.