Ontología para la exploración musical

Formalización, población y consulta

Grupo 2 | Octubre de 2026

1. Objetivo y revisión del modelo

La segunda etapa transforma los datos consolidados de 100.000 entradas musicales en una ontología reproducible. El producto considerado es un explorador de grabaciones, colaboraciones, obras y publicaciones: permite cruzar géneros y características acústicas, consultar créditos ordenados y recorrer las relaciones entre composiciones, ediciones y sellos.

El modelo conserva la distinción entre una **obra musical**, entendida como composición abstracta, y una **grabación**, que representa una realización sonora. Asimismo, un **lanzamiento** es una edición publicada; un **grupo de lanzamientos** reúne ediciones relacionadas. Álbum, sencillo y EP son especializaciones del grupo, no de la edición.

Cambio frente al modelo inicial	Justificación
Eliminar RegistroDataset y RegistroCancion del núcleo	Una fila no aporta por sí misma una entidad musical. Su evidencia se conserva en tablas identificadas mediante huellas SHA-256.
Eliminar AfirmacionExterna	Composición, producción e interpretación se expresan con relaciones tipadas, sin convertir todos los hechos en una misma entidad genérica.
Generalizar CreditoArtistico	Conserva artista, sujeto acreditado, nombre y posición. Puede pertenecer a una grabación o a un grupo.
Separar AnalisisAcustico	Evita mezclar tempo, tonalidad y descriptores de diferentes análisis o capturas.
Calificar publicación y género	PublicacionDiscografica conserva el catálogo del par edición–sello. AsignacionGenero conserva papel, votos y procedencia.

1.1. Estructura formal

El esquema tiene 19 clases y 70 propiedades: 21 de objeto y 49 de datos. Se genera con Python y RDFLib en `ontology.ttl`. Las clases se declaran con `owl:Class`; sus jerarquías, mediante `rdfs:subClassOf`. Persona y Agrupacion especializan Artista. Las propiedades incluyen dominio, rango, etiqueta y descripción.

El dominio de `tieneCredito` es la unión de Grabacion y GrupoLanzamientos. Una unión OWL evita el error de declarar dos dominios RDFS independientes, lo que implicaría pertenencia a ambas clases. Compositor y productor son roles compatibles expresados por `compuso` y `produjo`.

2. Construcciones OWL e interpretación

Se incorporaron once axiomas de cuatro tipos, además de las jerarquías y uniones. Cada construcción responde al significado del dominio.

ID	Construcción	Significado y justificación
A01	Clases disjuntas	Persona y Agrupacion: un artista individual no es un colectivo.
A02	Clases disjuntas	Grabacion y ObraMusical: la realización sonora se distingue de la composición.
A03	Clases disjuntas	Lanzamiento y GrupoLanzamientos: una edición no es el grupo que reúne ediciones.
A04	Propiedades inversas	apareceEn / contieneGrabacion: dos direcciones de la inclusión en una edición.
A05	Propiedades inversas	interpretaObra / tieneGrabacion: vínculo entre composición y realización.
A06	Propiedades inversas	perteneceAGrupo / tieneLanzamiento: pertenencia editorial.
A07	Propiedades inversas	tieneCredito / acreditaEntidad: vínculo entre el crédito y su sujeto.
A08	Cardinalidad exacta	Un CreditoArtistico tiene exactamente un artistaAcreditado de clase Artista.
A09	Cardinalidad exacta	Un CreditoArtistico acredita exactamente una entidad de la unión Grabacion o GrupoLanzamientos.
A10	Cardinalidad exacta	Una AsignacionGenero tiene exactamente un generoAsignado de clase GeneroMusical.
A11	Cadena de propiedades	tienePublicacion seguida de selloPublicacion implica publicadoPor. El sello de la asociación editorial publica esa edición.

2.1. Mundo abierto e identidad

Las cardinalidades son calificadas: restringen los valores de una clase determinada. Bajo la suposición de mundo abierto, la ausencia de un triple no prueba la inexistencia del valor. Dos URI tampoco prueban dos individuos diferentes. Por ello, una cardinalidad exacta no sustituye una comprobación de completitud sobre el archivo exportado.

No se declaran propiedades transitivas o simétricas sin justificación musical. Tampoco se usan MBID o ISRC como propiedades inversamente funcionales, ni se infiere `owl:sameAs` por compartir una etiqueta. Los identificadores locales diferentes no producen `owl:differentFrom`.

Los vínculos publicados se exportan explícitamente cuando están respaldados por una fila. La cadena A11 permite deducir la misma relación desde la asociación edición–sello. Fuseki consulta triples explícitos: cargar axiomas OWL no activa automáticamente un razonador.

3. Preguntas de competencia

Las preguntas se fijaron antes de poblar completamente la ontología. Se implementaron las ocho, superando el mínimo de cinco exigido. Todas consultan relaciones del modelo; sus resultados completos se entregan en CSV y JSON.

1. ¿Qué grabaciones tienen Rock como género mayoritario y un tempo medido superior a 120 BPM?
2. ¿Qué grabaciones acreditan al menos a dos artistas distintos y en qué orden aparecen esos artistas en los créditos de la grabación?
3. ¿Qué obras musicales tienen al menos dos grabaciones distintas que, en conjunto, acreditan al menos a dos artistas distintos, y qué compositores están asociados a esas obras, si se dispone de esa información?
4. ¿Qué grabaciones aparecen en al menos dos lanzamientos distintos y a qué grupo de lanzamientos pertenece cada uno?
5. ¿Qué sellos discográficos publicaron al menos dos lanzamientos distintos y cuáles son los títulos y los números de catálogo de esos lanzamientos?
6. ¿Qué grabaciones acreditan tanto a un artista individual como a una agrupación musical?
7. ¿Qué análisis de AcousticBrainz reportan tanto una tonalidad de do mayor como un tempo superior a 120 BPM y qué grabaciones describen esos análisis?
8. Para cada género musical, ¿cuántas grabaciones, artistas y grupos de lanzamientos están clasificados en él, contando por separado cada una de estas tres categorías?

3.1. Criterios operativos de consulta

Rock en la primera pregunta identifica el recurso del vocabulario tagtraum, con papel `mayoritario`. Los créditos de las preguntas 2 y 6 se evalúan dentro de una misma captura para no combinar listas publicadas en momentos distintos. Su orden es la posición original, en base uno.

En la pregunta 3 se cuentan MBID de grabación diferentes; dos referencias locales al mismo MBID no satisfacen el umbral. En las demás preguntas, cuando se devuelven grabaciones, se muestran referencias locales. Los conteos describen los identificadores representados en los datos, no una prueba ontológica de desigualdad entre individuos.

Los compositores, grupos y números de catálogo ausentes se conservan como valores no ligados mediante `OPTIONAL`. En la pregunta 7, tónica, modo y tempo deben pertenecer al mismo análisis. La pregunta 8 mantiene los géneros separados por vocabulario de origen y cuenta cada categoría de forma independiente.

4. Generación y calidad de las instancias

La transformación parte de los 39 CSV consolidados de la etapa 1. El vocabulario y las instancias se exportan por separado. El generador escribe incrementalmente para no mantener millones de triples en memoria. Las URI de grabación usan el identificador local `track_id`; las entidades externas conservan su identificador dentro de su clase. Las asociaciones emplean hashes de claves compuestas y captura.

Magnitud	Total
Referencias locales de grabación	100.000
Referencias con correspondencia aceptada	32.175
MBID de grabación aceptados distintos	32.140
Artistas	48.592
Obras musicales	10.003
Grupos de lanzamientos	33.277
Ediciones publicadas	57.373
Sellos discográficos	8.699
Créditos artísticos	65.032
Asignaciones de género	137.218
Análisis acústicos	118.203
Recursos de instancias etiquetados	742.915

Una correspondencia ambigua no proyecta hechos de sus candidatos. El volcado tiene prioridad sobre el piloto; un conflicto se registra sin mezclar grabaciones. En esta ejecución no hubo conflictos entre correspondencias aceptadas. Las 35 referencias adicionales que comparten MBID mantienen sus URI locales.

jMIR aporta 99.465 análisis de fragmentos. AcousticBrainz conserva 18.560 análisis del volcado y 178 del piloto, separados por captura. Un análisis compartido se vincula a todas sus referencias locales sin duplicarlo. La extensión del audio de AcousticBrainz no se presupone completa.

4.1. Etiquetas y procedencia

Toda clase, propiedad e instancia de dominio o evidencia tiene una etiqueta no vacía con idioma válido. Se usa `@und` para nombres cuyo idioma no está comprobado; las descripciones generadas usan `@es`. Wikidata conserva el idioma de sus etiquetas. Los nodos estructurales de OWL y las listas RDF están exentos; los recursos anónimos de dominio no lo están.

Cada CSV tiene una CapturaFuente con nombre y SHA-256. Los recursos enlazan las tablas que los respaldan. El informe de transformación registra las huellas de entrada y salida, los conteos y las filas sin proyección musical. Los campos no modelados permanecen en las tablas de evidencia: conservarlas no significa que todos sus campos hayan sido convertidos en triples.

5. Carga, consultas y validación

Apache Jena Fuseki 6.2.0 se ejecuta en Docker con almacenamiento persistente TDB2. El esquema y las instancias se cargan en dos grafos nombrados; la vista predeterminada consulta su unión. Ambas cargas devolvieron HTTP 201. Las consultas devolvieron HTTP 200.

El endpoint contiene 466 triples de esquema y 7.606.648 triples distintos de instancias, para un total de **7.607.114**. Las repeticiones textuales del archivo de exportación se eliminan por la semántica de conjunto del grafo. Fuseki confirmó las 100.000 referencias de grabación.

PC	Filas	Interpretación principal
1	2.731	2.709 referencias con Rock mayoritario y al menos un análisis superior a 120 BPM.
2	2.350	Créditos ordenados de 1.042 referencias con dos o más artistas en una captura.
3	278	96 obras con al menos dos MBID de grabación y dos artistas; incluye compositores disponibles.
4	63.643	Relaciones edición–grupo de 15.635 referencias con varias ediciones.
5	56.819	Ediciones y catálogos asociados a 4.388 sellos con dos o más ediciones.
6	489	Combinaciones persona–agrupación en 389 referencias de grabación.
7	789	Análisis en do mayor y superiores a 120 BPM, con su grabación asociada.
8	1.968	Géneros de vocabularios distintos, con conteos separados de las tres categorías.

Las filas no equivalen siempre al número de entidades: una grabación puede tener varios análisis, créditos o ediciones. Las consultas completas no usan límites que recorten los resultados. Los JSON preservan tipos y los CSV facilitan inspección; el resumen registra el hash de cada consulta y su tiempo de ejecución.

5.1. Controles de integridad

Un segundo motor, PyOxigraph, leyó los Turtle y verificó la ausencia de recursos sin etiqueta, etiquetas vacías o sin idioma válido, propiedades no declaradas, créditos sin artista o sujeto único y asignaciones sin género único. También se comprobaron los tipos explícitos disjuntos y la coherencia de la asociación edición–sello con la relación directa.

Las pruebas automatizadas incluyen casos negativos: no combinar créditos de capturas distintas, no contar dos referencias del mismo MBID como dos grabaciones para la pregunta 3, no atribuir el catálogo de un sello a otro y no combinar tempo y tonalidad de análisis distintos. Estos controles de datos complementan OWL; no se presentan como razonamiento completo sobre millones de triples.

HermiT, mediante Owlready2 0.49, confirmó la consistencia del esquema completo y la ausencia de clases insatisfacibles. Sobre casos controlados verificó seis inferencias: cuatro inversas, la cadena de publicación y la pertenencia de Persona a Artista. También detectó contradicciones deliberadas de disjunción y cardinalidad con individuos declarados diferentes. Esta prueba no ejecutó HermiT sobre la totalidad de las instancias.

6. Reproducción, alcance y dificultades

Los comandos se ejecutan desde la raíz del repositorio, con Python 3.11 o posterior y los CSV consolidados disponibles. Las direcciones de conexión están centralizadas en `src/configuracion.py`.

```
python -m pip install -r requirements.txt
python src/generar_ontologia.py
python src/generar_instancias.py
python src/validar_instancias.py
docker compose up -d --build
python src/cargar_fuseki.py
python src/consultar_etapa2.py
```

Los archivos de consultas están en `consultas/etapa2`. Los resultados y la evidencia HTTP están en `output/etapa2`. La documentación complementaria incluye el catálogo de clases y propiedades, las decisiones de modelado, el mapeo de CSV y las instrucciones del servicio. El código separa lectura, identidad, relaciones, mediciones, escritura y validación para facilitar su revisión.

6.1. Problemas encontrados y decisiones

- **Identidad local frente a externa.** Varias entradas pueden describir el mismo MBID. Se conservan las referencias locales y se explicita la unidad de conteo de cada consulta.
- **Capturas diferentes.** El piloto y los volcados tienen coberturas distintas. Créditos y análisis permanecen separados; una ausencia no implica inexistencia bajo mundo abierto.
- **Metadatos incompletos.** Hay publicaciones con catálogo y sin sello conocido. Se conserva el catálogo sin inventar un sello. Los nombres faltantes reciben etiquetas descriptivas deterministas.
- **Volumen del RDF.** El Turtle ocupa aproximadamente 1,69 GB. La escritura incremental y la validación con almacenamiento temporal evitan cargar todo el grafo en objetos Python. Se incluye una copia comprimida de aproximadamente 102 MB.
- **Alcance del enriquecimiento.** Se proyectan los hechos necesarios para el modelo y las preguntas. Otros roles musicales, eventos de publicación y propiedades de Wikidata distintas de género permanecen en la evidencia CSV. No se implementó el bonus de extracción de texto ni alineación con ontologías externas.

6.2. Referencias técnicas

[1] W3C. *OWL 2 Web Ontology Language Primer*. https://www.w3.org/TR/owl2-primer/

[2] W3C. *RDF Schema 1.1*. https://www.w3.org/TR/rdf-schema/

[3] Apache Jena. *Configuring Fuseki*. https://jena.apache.org/documentation/fuseki2/fuseki-configuration.html

[4] MusicBrainz. *Release Group*. https://musicbrainz.org/doc/Release_Group